



IMAD PROJECT 2026

Identificazione di Modelli e Analisi dei Dati

Predizione Carico Energetico

Analisi esplorativa · Feature engineering · Meta-modello di Blending

25

Sensori di
Temperatura

0-23

Time Stamp
Giornaliero

50.377

Misure Passate dei
carichi

Obiettivo del Progetto



Sviluppare un sistema predittivo in grado di stimare il carico energetico di un sistema per simularne l'andamento, sfruttando esclusivamente i dati di temperatura ambientale e temporali disponibili.



Input

25 sensori di temperatura
+ timestamp



Output

Previsione del carico energetico



Obiettivo

Massimizzare R^2 con dati disponibili e bilanciando complessità del modello

Esplorazione dei 25 Sensori di Temperatura

Correlazione Oraria


I 25 sensori mostrano correlazione nel tempo: aumentano e diminuiscono insieme seguendo i cicli giornalieri di temperatura.

Medie e Varianze Diverse

Ogni sensore ha media e varianza proprie, indicando posizioni fisiche diverse nell'impianto (zone calde, fredde, esterne).

Periodicità

Notiamo che la temperatura media del fenomeno osservato ha una netta periodicità nell'arco della giornata di 24h



Esplorazione dei 25 Sensori di Temperatura

Correlazione Oraria


I 25 sensori mostrano correlazione nel tempo: aumentano e diminuiscono insieme seguendo i cicli giornalieri di temperatura.

Medie e Varianze Diverse

Ogni sensore ha media e varianza proprie, indicando posizioni fisiche diverse nell'impianto (zone calde, fredde, esterne).

Periodicità

Notiamo che la temperatura media del fenomeno osservato ha una netta periodicità nell'arco della giornata di 24h



Esplorazione dei 25 Sensori di Temperatura

Correlazione Oraria


I 25 sensori mostrano correlazione nel tempo: aumentano e diminuiscono insieme seguendo i cicli giornalieri di temperatura.

Medie e Varianze Diverse


Ogni sensore ha media e varianza proprie, indicando posizioni fisiche diverse nell'impianto (zone calde, fredde, esterne).

Periodicità

Notiamo che la temperatura media del fenomeno osservato ha una netta periodicità nell'arco della giornata di 24h



Andamenti periodici del consumo



Dataset Randomizzato: Perché è Cruciale

✗ Senza Shuffle (Sequenziale)

- Il modello impara l'ordine temporale, non la fisica
- Impara pattern banali: 'il valore dopo X è simile a X'
- Data leakage: il futuro 'contamina' il training
- Falsa R^2 alta che crolla in produzione
- Non generalizza a nuove ore / stagioni

✓ Con Shuffle (Randomizzato)

- Ogni sample è indipendente dagli altri
- Il modello impara: $T_{\text{sensori}} \rightarrow \text{carico}$ (relazione fisica)
- Nessun leakage temporale nel training set
- R^2 robusta e replicabile in produzione
- Generalizza a nuovi istanti temporali

Decomposizione Ciclica del Tempo

Il timestamp grezzo (0–23) non cattura la natura ciclica del tempo: le ore 0 e 23 sono distanti numericamente, ma fisicamente adiacenti.


oraSin

$$\sin(2\pi \times \text{ora} / 24)$$

oraCos

$$\cos(2\pi \times \text{ora} / 24)$$

Entrambe le componenti insieme codificano univocamente ogni ora del giorno come un punto su un cerchio unitario.



Codifica Ciclica
dell'Ora

Fase 1: modelli polinomiali

Modelli polinomiali

Modello singolo parametro (orario)

$R^2 \sim 0.1590$ — troppo semplice

RMSE ~ 42


Regressione Polinomiale 2° (orario + $w_m(t)$)

$R^2 \sim 0.8352$ — migliora ma non basta

RMSE ~ 17

Limitazione

Non cattura interazioni tra sensori e non-linearità complesse



Fase 2: Reti neurali

Reti neurali

Prestazione della Rete Neurale

$R^2 \sim 0.95$





$RMSE \sim 10.281$

Limitazione

Un modello Blackbox non sappiamo tutto

Valore









Fluidità dell'andamento del sistema



Riepilogo Metriche — Validation vs Test

	MAE	RMSE	MAPE (%)	R^2
Validation	7.887	10.365	5.69	0.9508
Test	7.813	10.272	5.65	0.9518

Fase 2: Reti neurali



Fase 2°: Reti neurali

1 livello (16) neuroni

	MAE	RMSE	MAPE (%)	R ²
Validation	8.945	11.635	6.49	0.9380
Test	8.838	11.423	6.43	0.9404

1 livello (36) neuroni

	MAE	RMSE	MAPE (%)	R ²
Validation	8.643	11.270	6.29	0.9418
Test	8.532	11.073	6.22	0.9440

1 livello (64) neuroni

	MAE	RMSE	MAPE (%)	R ²
Validation	8.708	11.314	6.32	0.9414
Test	8.552	11.077	6.22	0.9440

2 livelli (64 - 32) neuroni

	MAE	RMSE	MAPE (%)	R ²
Validation	8.307	10.860	6.01	0.9460
Test	8.219	10.711	5.94	0.9476

3 livelli (128-64 - 32) neuroni


	MAE	RMSE	MAPE (%)	R ²
Validation	7.846	10.321	5.65	0.9512
Test	7.866	10.281	5.66	0.9517

Fase 3: Alberi - XGBoost

Implementazione avanzata del *Gradient Boosting*: veloce e preciso.

- **Regolarizzazione:** Tecniche L1/L2 contro l'overfitting
- **Parallelismo:** Uso ottimizzato della CPU
- **Pruning:** Elimina i nodi a basso contenuto informativo.

Prestazioni xgBoost_model



Riepilogo Metriche xgBoost_model


	MAE	RMSE	MAPE (%)	R ²
Validation	6.586	8.955	4.69	0.9630
Test	6.464	8.624	4.63	0.9664

Fase 3: Alberi - LightGBM

Modello ad alte prestazioni per l'analisi massiva di dataset complessi

- **Leaf-wise growth:** Cresce per foglia, non per livello
- **Ottimizzazione tramite Istogrammi:** Raggruppa i dati in "bin" per massimizzare la velocità
- **Efficienza memoria:** Progettato per gestire dataset ad alta dimensionalità

Prestazioni lgb_model



Riepilogo Metriche lgb_model


	MAE	RMSE	MAPE (%)	R²
Validation	6.779	9.154	4.86	0.9614
Test	6.732	8.877	4.86	0.9644

Fase 3: Alberi - CatBoost

Modello di Boosting simmetrico progettato per la massima stabilità predittiva

- **Ordered boosting:** Permette al modello di non imparare pattern errati, assicurando una previsione basata solo su tendenze reali
- **Robustezza:** Gestisce con naturalezza eventuali rumori nei dati termometrici
- **Alberi Simmetrici :** Garantisce una velocità di risposta eccezionale

Prestazioni cat_model



Riepilogo Metriche cat_model


	MAE	RMSE	MAPE (%)	R²
Validation	6.645	8.961	4.77	0.9630
Test	6.551	8.703	4.74	0.9658

Fase 3: Rete Neurale - MLP

Il Multi-Layer Perceptron (MLP) cattura le relazioni non lineari "nascoste" tra tempo e carico.

- **3 Livelli Nascosti:** Struttura 128-64-32 per spiegare pattern complessi.
- **Interazioni Globali:** Eccellente nel catturare relazioni tra i 25 sensori
- **Flessibilità:** Si adatta a dinamiche di carico che sfuggono agli approcci tradizionali.

Prestazioni MLP Rete Neurale



Riepilogo Metriche MLP Rete Neurale


	MAE	RMSE	MAPE (%)	R^2
Validation	8.098	10.722	5.80	0.9467
Test	7.989	10.390	5.77	0.9513

Fase 4: MetaModello - RidgeCV

Non scegliamo un vincitore, ma uniamo le forze:

- **Ponderazione Ottimale:** Identifica matematicamente il contributo ideale di ogni stimatore
- **Diversità:** Permette di compensare i punti ciechi di ogni singolo modello.
- **Regolarizzazione e Stabilità:** Ridge applica una penalità L2 che previene la dominanza eccessiva di un singolo modello


Prestazioni blendig_metaModel



Riepilogo Metriche blendig_metaModel

	MAE	RMSE	MAPE (%)	R ²
Validation	6.282	8.572	4.47	0.9661
Test	6.147	8.274	4.42	0.9691

Performance del Sistema Finale



Performance del Sistema Finale

Metrica di Performance	Set di Validazione	Set di Test
MAE (Errore Medio Assoluto)	6.282	6.147
RMSE (Errore Quadratico Medio Radicato)	8.572	8.274
MAPE (Errore Percentuale)	4.47%	4.42%
Coefficiente R ²	0.9661	0.9691